



Proposta de Arquitetura para utilização de Redes Neurais Profundas na detecção automatizada de desmatamento no Cerrado.

O mapeamento das áreas antrópicas produzido pelo PRODES-Cerrado constitui uma importante base de dados para o monitoramento do desmatamento no bioma Cerrado. Segundo a validação amostral e independente conduzida pelo LAPIG/UFG, este mapeamento possui $93,17 \pm 0,89\%$ de acurácia global e encontram-se em constante processo de melhoria, em decorrência do acúmulo anual das áreas antrópicas do bioma (Parente *et al.*, 2020). Por se tratar de uma base de dados com elevada acurácia e produzido por interpretação visual de imagens de satélite, o PRODES-Cerrado tem um enorme potencial para ser utilizado como amostra de treinamento em métodos de aprendizado de máquina supervisionados. Este potencial já foi explorado para o PRODES-Amazônia e apresentou resultados com 95% de acurácia, em 4 cenas Landsat localizadas no sudeste do Pará, utilizando redes neurais profundas (Maretto *et al.*, 2020). A utilização de rede neurais profundas em dados satelitários pode ser considerado o estado da arte para geração automática de mapeamentos, superando técnicas clássicas como o algoritmo Random Forest, porém demandam de um elevado investimento no levantamento de amostras de treinamento (Parente *et al.*, 2019).

Assumindo que toda a área mapeada pelo PRODES-Cerrado pode ser utilizada como amostra de treinamento, a avaliação das redes neurais profundas no bioma Cerrado torna-se viável e necessária para o projeto. Nesse sentido o LAPIG elaborou uma proposta de investigação embasada na avaliação de uma rede neural recorrente (i.e. LSTM) e convolucional (i.e. U-Net - Figura 1). Nessa proposta, a LSTM será capaz de avaliar todas as imagens obtidas ao longo de um ano PRODES (e.g. Jun/2017 à Jun/2018) buscando por rupturas na série temporal associadas aos eventos de desmatamento. De forma complementar, a U-Net irá buscar padrões espaciais e relações topológicas que caracterizam o desmatamento entre duas datas distintas, padrões estes muito semelhantes aos avaliados na interpretação de imagens realizada pelo INPE.

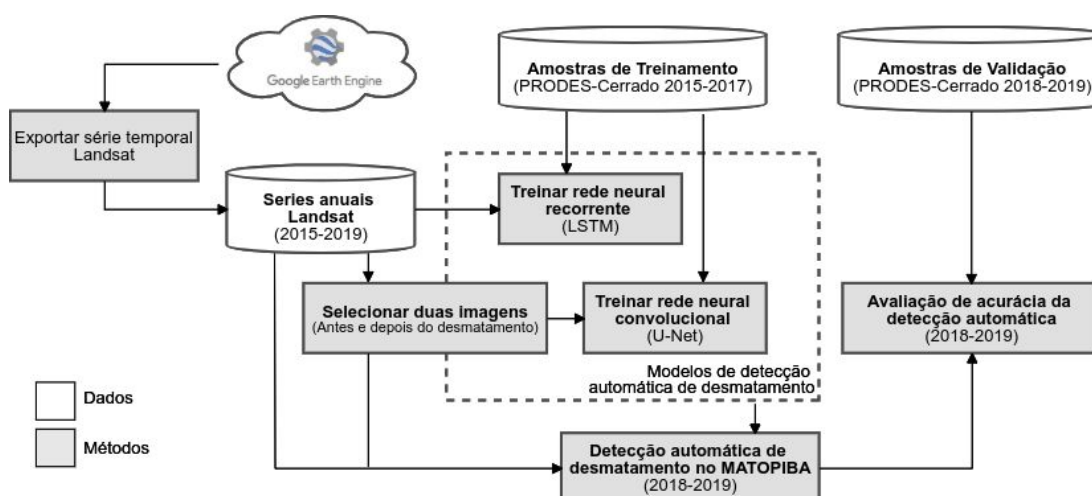


Figura 1. Proposta metodológica para a detecção automática de desmatamentos utilizando redes neurais profundas.

Como o PRODES-Cerrado inspeciona duas imagens Landsat (uma antes e outra após o desmatamento), todas as imagens compreendidas entre o período de inspeção devem ser adquiridas, organizadas e avaliadas pela LSTM. Considerando o volume de dados envolvido neste processo, o mesmo pode ser implementado no Google Earth Engine-GEE, plataforma de computação em nuvem que dispõem de todo o acervo Landsat do planeta e funcionalidades de análise e exportação de dados. A exportação deve ocorrer por órbita-ponto, gerando um arquivo por banda espectral (*Blue, Green, Red, NIR, SWIR-1* e *SWIR-2*), com as datas de obtenção organizadas em bandas GeoTiff (formato suportado pelo GEE), resultando em 6 arquivos finais. A banda de qualidade (BQA) também deve ser exportada como um arquivo à parte, uma vez que os pixels contaminados por nuvem e sombra de nuvem não serão ser filtrados/removidos dos arquivos exportados, na expectativa que a LSTM seja capaz de ignorar os valores anômalos e ruidosos da série temporal espectral. A U-Net irá considerar exatamente as mesmas imagens avaliadas pelos intérpretes do PRODES-Cerrado, o equivalente a primeira e a última imagem da série temporal da LSTM.

Como as amostras de treinamento da LSTM são coordenadas geográficas (pontos) e da U-Net são polígonos, deve-se utilizar um único e consistente desenho amostral para as duas redes neurais, buscando assim obter resultados comparáveis entre si. Nesse sentido sugerimos a utilização da estratégia definida por Parente *et al.*, 2019, a qual amostrou polígonos e pontos nas mesmas regiões geográficas, e considerou uma estratificação baseada em classes de uso e cobertura da terra. Para o contexto do PRODES-Cerrado, os polígonos de desmatamento podem ser classificados conforme as classes de uso e cobertura do MapBiomass em 1999 (coleção 4.1.), ano imediatamente anterior ao seu ano base. Como as redes neurais serão treinadas para detectar automaticamente o evento de desmatamento, a quantidade de pontos e polígonos de treinamento deve ser equilibrada em 50% de amostras de desmatamento e 50% de amostras de não-desmatamento, porém esta relação pode ser alterada após a análise dos resultados.

O treinamento das redes neurais pode ocorrer de forma preliminar tendo por referência uma ou duas cenas Landsat, porém consideramos que a área de estudo ideal para essa avaliação seja o Matopiba, uma vez que nesta região encontra-se a maior área de vegetação remanescente do bioma Cerrado, com variadas fitofisionomias (e.g. florestal, savânica, campestre) e diferentes classes de uso e ocupação da terra. (e.g. soja, algodão, milho, cana-de-açúcar, pastagem). Recomenda-se que essa avaliação considere amostras obtidas entre 2015 e 2017, as quais foram efetivamente geradas no âmbito do projeto, para compor o conjunto de treinamento, e amostras de 2018 e 2019 para compor o conjunto de validação, avaliando assim a real capacidade de generalização das redes neurais e seu potencial de utilização na detecção de desmatamento em anos futuros. A implementação da LSTM pode utilizar o código fonte disponível em <https://github.com/NexGenMap/dl-time-series>, e a implementação da U-Net pode ocorrer conforme Maretto *et al.*, 2020 ou por meio do código fonte <https://github.com/NexGenMap/dl-semantic-segmentation>.

Referências

Parente L.; Nogueira S.; Baumann L.; Almeida C.; Maurano L.; Affonso A.; Ferreira L. PRODES CERRADO: Monitoring deforestation in a global biodiversity hotspot. Submitted to Remote Sensing Applications: Society and Environment. 2020.

Maretto, R.; Fonseca, L.; Jacobs, N.; Körting, T.; Bendini, H.; Parente, L. Spatio-Temporal Deep Learning Approach to Map Deforestation in Amazon Rainforest. *IEEE Geoscience and Remote Sensing Letters*, 2020.

Parente, L.; Taquary, E.; Silva, A. P.; Souza, C.; Ferreira, L. Next Generation Mapping: Combining Deep Learning, Cloud Computing, and Big Remote Sensing Data. *Remote Sensing*, v. 11, n. 23, p. 2881, 2019.